

3 Dars. 1. Pre Training vs Post training.

Pre training modelga dunyo xaqiqlari umumiy bilim
vati strukturasi next token prediction orqali
o'rgatish boshqidi. Bu yerda milliardlab trillions
token ishlatiladi va model internetning konperasiya
layihalariga aylana.

Post training (SFT / RLHF / DPO) model
xatti xarakterini insonlar kutgan formatga
aylantiradi fozdali xavfsiz konsotmay riyoga
qiluvchi moslashtiradi.

Pretraining nima bilishni o'rgatadi.

Post training qanday gapirishni o'rgatadi.

2. Common Crawl to'g'ri to'g'ri ishlatib bilmayligi.

Xon Com Crawl HTML boilerplate
navigatsiya elementlari duplicate saxifalar
spam postlari avtomatik generatsiya qilingan
matn va fil aralashtirish mavjud.

Xon negt buni yoqilgiga o'ylantirish uchun to'g'ri.

3. Fine Web nima?

Hugging Face tomonidan Common Crawl tomonidan
chizilgan top bog'lanli filtrlash.
fil aniqdan sifat klassifikatsiya, odatda odatda
ozgali tozalangan training web to'g'ri
korpusi.

4. gitignore ichidi nima bo'lishi kerak.

Model o'g'irliliklari checkpoints, pt / safte ensa
datasetlar API kalitlar tokenlar, env fayllar.
maxiy molunotlar.

5. API kalit repositoryga fusli qo'yilmasa
qilish kerak.

Taqqat fayl o'chirish xato git privet
u hali ham maxfiy bo'lsa. Kalitni darkol
revoke qilish, rework birinchi clear uyitish.

6. Nega GPU nega CPU emas.

Transformer training massiu matritsa
kopaytirish operatsiyasida break bulon parallel
tirish mumkin bo'lgan farasalar. Misolga
kiritish yodrolonga ega belarda parallel ishlashga
CPU xonalarisani bu agilli yodrolonga ega
uni ketma ket murakkab operatsiya bajar.

7. Data mixture nima va nega bitta dataset
yetarli emas?

Hozir xil momba xar xil qabilgat o'g'atish.
shuning uchun balansli qabilgat uchun
data mixture zarur.

8. Deplotli qatlar nima va nega olinoladi
qilinadi?

Deplot kizkil yoki yori o'lgan bir xil
nizmatni topusda olib tashlaydi. Buni da
ol training o'lgan anar qilish.

9. Katta korog data avtomatik yaxshiroq model ekanligi sifat va hajm nuqtasi o'zgaruvchiligi, 10 TB span — 100 GB yuqori sifat kichiklik matnlar yomurga natija beradi.

Garbage in Garbage output.

10. MIT letseziyasi: dataset ustida train qilganingiz nima talab qiladi.

MIT juda permissiv lekin shartsiz emas. Data lineage licensing Notice namunasini ko'ri.

11. Coding LLM uchun data mixture dizayni

Texining tarqib 40-50% (Python, JS, Java) bilan boglangan holda.

Technical web (Stack Overflow documentation 20-30%)
General web text 15-20%

Math/Science 5-10% Books/References 5%

12. Compute sarflashdan o'tirish corpus sifatini qanday o'lchash mumkin.

Perplexity proxy, Ngram statistikasi. Klossik based scoring. ablation training.

13. Aqlliq silvestris data hajmini saqlash o'rtaidori trade off, Aqlliq filial sifatini oshirish, unique tocer hajmini kamaytirish distribution tugashlar o'rtaidori mumkin.

14. Denmark leakage garibay arizlar?

Asosiy asul n gram overlapping tekshiruv.
MMCU, GSMK va h.k. Asosiy is solishtiruv

15. Exact vs Fuzzy qadon ishlatiladi?

Exact dedup (Mof SHA hashlash),
Bir xil muayyan topaqa ter va arava.
Birin o'ziga o'zgaruvchan bittir soz fargi o'zgaruvchan
o'tkazib yuboradi.

Fuzzy Minhash + LSH chugun fashir qimmi
Avalanzor kegir fuzzy e'ni.

16. 80% ingliz corpus birin o'zbek joylabalarini
ulovun maxsulot?

Ikki qatlamli yechim. Data olarajasiolagi
o'zbek filologiya detouri unsampling qila,
toreni zemi o'zbek filologiya katta korpusda
train qila.

17. Sagity /PII filitiratsiya overfitting
xavfi qit ignore xavssizlik mexanizmi?

Sagity ikki tomondan xavfida
haddan fashigari agressiv qit2 legitim tibbiyot
huguvot fashigari katta. qit ignore olar
vositachisi qit fashigari kurti o'tkazib
sagityli