

4 Dars Data Engineering Pipeline

Xon matndan LLM uchun tola copas ~~shayos~~.

Nega ma'lumot pishiriishi kerak?

LLM juda o'qolay printsipti bo'ysunari
u nima ni o'qitishni o'rganadi.
Agar usha tantibisiz ixti markat tarroble-
nashlon shigirish matn bebsar.
u har xobli shu sigatda bilimni yoo'lab
olash. garbage in garbage Output.

Cleaning $\Rightarrow$ Filtering $\Rightarrow$ Deduplication $\Rightarrow$
PII scrubbing $\Rightarrow$ statistika hisoboti.

Atkinsonlar yozilgan sintetik ma'lumot

Hujjatlar soni 2,119,719

Belgilar soni 1,859,773,203

Fayl hajmi 1870.22.M

Birindii bosqich Cleaning

Har qanday Raw data shu iflos elementlar
bo'ladi. HTML taglar bir xil kengayish
kerli urinishi o'rinli bo'ladi.
koinmas boshqaruv belgilar.
Agar bulami tarolomay mode bir xil
sonni itki xil tovar sigatda o'qish

HTML teghlami olib tashlar,
Entities dan ~~flexible~~ group: $\Rightarrow \emptyset$

Unicode NFC KC normalizatsiya,

köshma bo'lgan belgilar.

ortiqh boshli bog'liq.

Filtiriz.

Toraleshoblar sōng huyat gramatik
jihatlar to'g'ri bo'lsa, aqsa ikratlar
kouranda manaa, dege threshold
jok qatag bo'ssa o'ynat ki aqlan -
jokde yuray shogin to'g'ri
muammarl chog' yor.

Deduplication

Eng maxin eng rōp Natija beradigan
bosqir Compute is rōgi X
Memoriae xarid X

PIT scrubbing nizer derdi.
Dang analisthi masala.

Oxirgi tizlar bosqidi sharsiy malumot
ni qoblar. Xarfli gim almatiri can.

Statistika hisoblash jarimi
hisob kitob

Raw 2,119,713

Cleaned 2,119,489

Filtered 2,119,350

Deduplicated 1,789,164

Final 1,789,164

Pipeline har bir bosqichida
vaqtga ega emaslik b
toza o'qib olinadigan maxfiylik
jihatidan xavfni korpusga aylantiradi