

5 Dars.

Ushbu dars tozalangan matnni til modeli o'qiy
oladigan xotira ji'xatidan tayyor va o'qitishga
tayyor ragamli formatga aylantirish jarayoni

1. Tokenizator matnni model olib olishga
tokenlarga ajratadi.

2. Dataset guruvi tokenlarni ishonchli bo'lgan
sizilgan ixtilis formatga saqlaydi
va keyingi tokenni bashorat qilish vazifasiga
mos kiritish ushbu justliklarini yaratadi.

Tozalangan shaxsiy ma'lumatlardan xoli kuyga

↓
Publicatlarini yozotish

↓
Hujjat darajasidagi train / validation / test

↓
Fagat. train hujjatlarida tokenizatorni o'qitish

↓
Har bir hujjatni kodlash va eos > qo'shish

↓
unit 16 formatidagi train.bin / val.bin

↓
np. memmap orqali bloklarni o'qish.

$x[t] \rightarrow y[t] = x[t+1]$

↓
Til modelini o'qitish

1. Tokenizator oddiy matn ajratuvchi emas va modeling iqtisodiy va texnik arxitekturasini qayta ko'rib chiqishni talab qiladi. Chunki model parametrlarini o'qitish tezligi va uzunligi GPU saqlash o'qitish tezligi model bir kontekst oqimiga qarshi vaqt masofasini sig'dira olishini belgilaydi. Shuning tokenizatori noto'g'ri tanlash keyinchalik model arxitekturasini optimallashtirish bilan to'liq qoplamaydi.

2. Data setni to'g'ri qurish baholash natijalarini ishonchligini belgilaydi.

Bir kichik qismning train va validationga to'planiga taqsim etiladi. Model mazmunini oldindan ko'rgan bo'ladi. Natijalar validation yozgichini qurishda yaxshi ko'rinadi.

3. Kod ishlatilgan degan data set to'g'ri o'lgan emas. Round trip identifier diapazoni fayl hajmi ma'lumatlari ceos7 o'zgarishi x/y siljishi alohida avtomatik testlar bilan tekshirilishi kerak.

Tokenizator metr va model o'rtasidagi farqni,

Subword va Byte level BPE

Matnni modelga uzatishda 3 ta asosiy yondashuv mavjud.

belgi olagisi: har bir harf alohida token.

Söz olagisi: har bir butun söz alohida token.

Subword olagisi: so'zlar tez-tez uchraydigan qismilarga ajratiladi.

Belgi $\rightarrow$ lugat kichik bo'lin ketma ketlik uzun bo'lin

Söz - ketma ketlik qisq. bo'lin lugat ulanadi.

BPE shular o'rtasidagi muvazana

Kitob tarkibidagi

BPE bunday bo'linish grammatik jihatdan bilan eng korpusdagi takrorlanish o'rtasidagi o'zgarishga.

Nima uchun muhim.

Yangi token yoki kam uchraydigan so'zlarni yozilgan.

Keng tarqalgan qismlar bitta token bo'lib ketma ketlik qisq.

model xotira; va hisoblash qismi muvazana

harli yozil fikrlarining must qayta, o'zlash mexanizmi saqlanadi.

BPE merge qoidalar.

BPE dastlab matnning eng kichik birliklari ajratilgan keyin taxminan ravishda.

1. Yonma yon kelga barcha juftliklarni tanlash.
2. eng ko'p uchragan juftlikni tanlash.
3. shu juftlik yangi katta token sifatida kiritiladi.
4. qoidani royxatga yozadi.
5. maxsusli kuzat harfni yetguncha jarayon davom etadi.

Lugat harfni muvazirati.

kichik lugat. $\rightarrow$ Embedding va chiqish qatlam kichikroq tokenlar ko'proq misol bilan
Matn ko'proq tokenlarga ajraladi. ko'proq
tor to'ladu.

Kattalug'at $\rightarrow$ Ketma ketlik qisqartirish.
Ko'p so'zlar yirik birlik bo'ladi.

Parametrlar va laqib & softmax kategoriyalar.
Noyob tokenlar ko'p o'rganiladi.
Tavsiya etiladigan metrikalar.

Fertility: tokenlarni / so'zlarni. Past bo'lsa yangi
Sizil ko'rsatkichi belgilarni / tokenlar soni.
Bart / token: ko'pchilik matnning belgisi.

Token (sekun) - harfning o'qitish. tesirli.
Validating perplexity.

lugat hajmi bevosita

GPU xotirasiga bo'g'liq

Train va generatsiyaga terligiga

Konteks oynasining real mazmun sig'iniga
diskdagi tokenlar soniga.

Özbekcha va boshqa dionmlarga sanovash riga
qo'shish qiladi.

Maksus tokenlar.

Massus tokenlar oddiy matnda o'zgaribmaydi.
Ular tizim tomonidan ma'lum holatlarini
belgilash uchun qo'shildi.

Ceos 7 Hujjat yoki ketma ketlig tugagorini
bilolizadi. Zaver,

<boss> ketma ketlik boshlangari bilolizadi
Ixtiyoriy.

Cpaol 7 Turli usulicher namunalar teng bo'lishadi.
Flat patching kerak emas.

Qun k 7 ifodalash bo'lmaydi birlikni bilolizadi.

Ceos 7 bo'lmasa nina yuz beradi.

Hujjatlar bitta usul oqirga ulanib ketadi.

Model bir hikoyani ya'ni birinchi boshq

hikoyaning boshlanishi tabiiy o'laran

oleb o'zgarishi mumkin.

Bunday foshqon

generatsiyani qachon tugashi ceratligini

bilolizadiga, anig Signal qolmay.