

Y Dars.

LLM Model Design.

Ötgan darslarda Data ni yig'ish tashlash (HTTPC to'g'ri va shaxsiy ma'lumotni olib tashlash) filtrlash va duplikatsiya olib tashlash kabi Data Engineering bosqichlari to'g'ri yachunlar.

Shuningdek Data ni Tokenizator (BPE) orqali kompyuter tushunadigan ragaarlarga Token ID o'g'irilib va porziyalarga (barcha) o'g'iradi.

Endigi navbat eng muhim bosqich. Tayyorlangan ideal ma'lumotlarni qabul qilib ulardan o'zgaruvchiligi Transformer arxitekturasiga o'zlashtirish LLM o'lashtirishni qurish.

1. Vocab Size = 8000

Model tushunadigan vogene arbiya qila o'lashtirish. Jami unikal tokenlar lugat soni. Bu g'ymad datasets / meta. json fayl o'lashtirish g'ymad bilan mutloq bir xil b'lishi short va max token ID 7399 ga teng b'lashi.

Xat lric va Yedim: Agar matnda model lugati 759 8001 s'z icilib q'lsa OOV dastur Index Error berib q'lashtirish. Yedim Sifati, maxsus <unk> tokenlar, fayllarni kash, yoki s'z BPE orqali model b'lashtirish.

Kichik qismlarga masalan 0-7999 oralig'ida
to'rtga b'lib yuboradi.

Block size < bos >

O'xirgi < eos > maxsus to'rtlarni
shu lugatga kiritadi.

Block size $\Rightarrow$ Modeling ichki xotirasini,
ya'ni bir martaq, qabul qilib o'g'iy o'ladigan,
marginal to'rtlarni soni. Potensial to'rtlarni soni
0 dan 255 gacha b'rtadi. Agar 257 to'rt kiritilsa,
model uni qabul qila olmaydi.

Resursga ta'siri Ushbu oyna kattalashgani sari
GPU xotirasining sarfi faqatgina 0 (T?)
ravishda keskin oshib boradi.

$n_embed = 384$. Embedding dimension Har bir to'rt
butun son model ichidagi shunda ushbu to'rt
harfiy sonlar float to'rtlarga o'tib o'tirish
o'zgartiriladi.

$n_head = 6$. Attention heads. Model natijaga
faqat bir tomondan emas birlaniga o'xshash
parallel martig'iy olingan natijalarni
o'zgarishi kerak.

Hisob: $head_dim = n_embed / n_head = 384 / 6 = 64$.

$n_layer = 6$.

Model chuqurligi yoki ketma ket ustma ust
to'rtlarga Transformer bloklari soni.

Qatlan sari ko'paygan sari martig va teshuvith
reasoning abstract. qobiliyati endogor
lekin train farayani serinlashib boradi
7 layer baraviy granatlar solan ketma ket qay.

6 layer sora bi tashitib qisqa paralarini o'zgar.

6 layer. ma'lum fi krlashni o'zgar.

dropout = 0.1

MM Overfitting rizg oloini oluvchi mexanizim
vaishda 100% o'chirib qayadi. Model topshir
ga (inference vaqtida) bu qiymat avtomatik
vaishda 0 ga tushiriladi.

SLM uchun dropout ishlatiladi.

CCM odatda weight decay usulidan foydalanadi.

ffn_mult = 4.

Feed Forward Network. ning kengayish
ko'rsatkichi. Attention datalarni bir-biriga
bog'likligini ta'riflaydi. FFN ularni
qabul qilib olib b. l. im sig'ida o'zida saqlay
qoladi. Database / DB.

Hidalar bari $384 \times 4 = 1536$ Neuronlarda
kengayadi.

tie_weight = True.

Modeling xiroh (Embedding) va chiqish
LM Head qatlarining va'zalarini bog'lay
bitta umumiy feyvaldan foydalanishni ta'minlaydi.
Buning hisobiga model nagd. 3.1 000 000
ozig'cha parametar tejayot. GPU VRAM
kutilasini sezibadi boshlash.

head_dim. Har bir attention kagligi ideal holda
64 b'lishi erak. Agar goldig b'lar son
b'lar GPU crashed xat'isini baradi.
Yechim n_embd yac n_head o'zgartiriladi.
Short.

Total params. Modeling umumiy key zarlar
va bog'lanishlar o'g'irlik. 5M ~ 15M
Agar u feyvalni boshlashni k'lsq
 n_layer yalci n_emb ni kamaytirishga to'g'ri.

Modelga internetdan olingan katta xom
matn kirib keladi. Bu yerda cop axlat
va keraksiz ma'lumat bo'lsay
ular 3 ta filtrlardan o'tadi.

1. Data Cleaning (Tozalash Normalizatsiya)
taglardan iboratlash. Fagat so'zlarni
qoldiriladi.

PII o'chirish: Shaxsiy ma'lumatlar atqari
tiklarda phone email kabi yopiq
sözlarga aylandi.

2. Data filtering.

Tarkibi juda ko'p xatolar, uzunligi 0 to 1500,
yoki yomon so'zlar bilan, file matnlar
o'chiriladi.

3. Deduplication. Tarkibi do'kumlar matnlar
o'chiriladi.

Sof matn korpusi

Dataset analysis.

Vocabulary lugat yaratish Merge Process,
Tizimni Tashkil etish.
Tizimni unga qarab Vocabulary
yaratish boshlaydi.

BPE.

Algoritmi matni boshlar oxirlarida
o'qib diqqat qo'yib kelgan qaysi
2ta belgi eng ko'p takrorlanayotganini tanib.

Merge
eng ko'p takrorlangan 2ta belgi
merge qila va uni yangi token sifatida
qo'shadi.
Buzilgan vocab size qancha belgi bo'lsa
shuncha daraja etadi.

Tizimni yaratish.

Vocabulary yaratish tayyor bo'lgach
har bir sub word (Token) 512da
Buzilgan son 1D beriladi.

Matnlar 1204 305, 0 $\rightarrow$
matritsaga aylantirish Transform Embed
qilinishi 302 512.