

Dars-3.

1. Vocab-size parametri nimani anglatadi va u nima bilan bog'langan?

Bu model qabul qila oladigan va ishlatiladigan unikal tokenlar soni bilaligan.

Nomalar söz ki ritilish tarzida kodlanadi. Yoz buzilmaydi. Zamonaviy tokenizerlar nomalar sozlarni kichikroq, ma'nu bo'lgan qismlarga bo'lib tashlaydi. Agar umuman tanilmaydigan belgi keladigan, u maxsus UNK tokeniga almashadi. Shu sababli tizim to'xtolmaydi.

2. ~~Q~~ Block-size (yoki context-size) model bir vaqtida o'rida ko'ra oladigan maksimal tokenlar soni. Uning chegarasi. VRAM va Self Attention hisoblash murakkabligi bilan cheklangan.

3. n embed nima va u qanday tokenlarni o'z ichiga oladi?

Embedding o'lkani $\rightarrow$ raqamli token. Vektorining o'lkasini maxalan token #513 raqamini keng matematik va grammatik ma'no ega bo'lgan koordinatalarga tizimiga ko'chiradi.

4. Qatlamlar soni n -bosh oshqandagi
texnika nima uchun beradi

Model dargirdashadi, va ma'lumat
qayta qayta qayta abstraksiya qilish
nusxalar mantiq o'zgarib badi
Har bir qavat dolirigisining yiriklik
bilimini dargirdashliradi.

5. Attention Headon (n -head) nima va nega
ular parallel ishlaydi.

Bular modeling bittamotaga turli tarzda
qarashini uchun xizmat qiladi. Mexanikali

Masalan bitta bosh sizning ishlaydigan
qarab rannoni aniqleshtirish, ikerikli bog'lar
digan qiladi.

Nega n -end parametrlar n -headga
qoldirgisi bolarishini nerek. Chunki,
ammaiy vector olcha PyTorch ichidagi
barda headlarga teng tengsizliklar
Shape Error bolar.

6. Pretraining davrida dropout 0.1
qanday regulirizatsiya qilindi.

Har qadon Neurons 10% ni foxalifiy
ochiradi. Overfitting X

Jonli ishlab inference depart qolishi
cerakni. Odatiyan yog. Jonli ishlab
barcha neyroni ushga tushish natijasi.

1. FFN layerining asosiy vazifasi.
Attention sozlovni biz bizi bilan boglay
FFN ha biz sozuvchi, yakko ozi ishlay
model xotirasig bilmu va farketlari
shu song bizintiradi. Non linear pro.

Nega ffn-ni yordamida $4 \times$ kengaytiri
yana o'ziga sigiladi. Modulya boyroq
tassilotlarni qidirish uchun ishchi mayor
yamotadi. Eng kerakli kelosani olirga
u keraksiz Noisedor tozalarni yasa
sigiladi.

8. tie-weights: true ornati lishining manosi
nima?

Javob: Bu amurda Tokunlarni Vektorga
aylantiruvchi gatlarni va Vektorni qayda
to'unga aylantiruvchi gatlarni CH Heay
ovra bir xil ogirlik matritsasi fagali.

9. Step o'dagi Random init loss

nima uchun nuskun.

Traindan o'tib, model barcha layerlarini
faydalanib o'qitilgan matematik funksiyalar

10. Generatsiya ichidagi Greedy Decoding

nima?

Model barcha o'qitilgan layerlarini
ehtimolliklar hisobida qat'iy
tavishlar bilan o'zaro e'lon qiladi
ehtimollik to'xtatish tashabbotlarini
uzuni

O'ta Daraja

1. Causal Self Attention va Global
Attention ni gap yordamida foydalanib
Kelayotgan va ko'rinib qolgan.

Training LLM Causal usulini ishlatish
shart.

Agar Causal Mask niqobini pretrain qilish
olib tashlansa, nima bo'ladi.
Model shunchaki kelganday, faqat faqat
kodi rib yoritish o'rganib o'tadi.
Loss $\rightarrow 0$, lekin model inference
amaliyotida ishlamay qoladi.

2. Nega parametrlar tokenlar byudjetiga ariz moslashtirilishi kerak?

Kichik ma'lumotlar (tokenlar) bilan o'ta katta modelni o'qitish undan trainingga olib keladi.

Bunga sabab model parametrlarini to'laqquli o'qilishi uchun yetarli martig'iy misol kismay. Chin chilla qoidasiga (1 parametrlar = 20 token) binoan 100M tokenli byudjet uchun qaysi o'lcham ideal. $100M / 20 = 5 \text{ million}$.

3. Nega faros q o'dan emas balki 0,02 standard o'g'ish bilan (std) initsialitsiya qilinadi?

Matematik simmetriyani buzish o'ylashi. Neyronlar boshida har xil kichik varislar bilan boshlashi kerak.

4. Pre Norm o'rnatishning ustunligi nima?

Normalization avval layer (Attention / FFN) ichiga kirmasdan oldin o'rnatilishi NN data o'qimini barqaror qilishni ta'minlaydi.

5. Residual Connection + qanday vazifani bajaradi.

Blockni aylarib o'tuvchi data ter juvarg'ochi. U original kirishlarni murakkab jarayonlar bilan o'tgan natijaga to'g'ri to'g'ri qo'shish bilan data buzulish o'lchoshini to'xtatadi.

6. Causality Test barqarorlikni qanday
tasdiqlaydi.

Agar matnning 5-sözi o'zgartirsa 1 dan 4 so'zga
bo'lgan bahoratlarda hech qanday o'zgarish
bo'lmazligi kerakligini tekshiradi (vaqt tengligi
oqimligi).

7. FFN nega har bir pozitsiya uchun Alkhida
ishlaydi.

Chunqi xalasi aralashtirib kontersin
fushunish va xifasi ni Attention bo'yisib bo'lgan

FFN esa Bu so'z o'z o'rnida aniq qanday
ersik lopeidia maro bi Coliruvchi deya savolga
individual shug'allashtirig'ga javob tayyor.

Attention Token lar ara mulozot markasi
FFN isolatsiya qilingan niga (play fast)

8. Overfit one batch testidan muldaro nima?

Modelga atiga bitta mitti matni berib
yodlatishi so'radi. Agar loss aniq rolgan
tushib ketsa demak kodning fundamental
mekanikasi da (forward/backward pass),
common misson I O I.

9. Gene ratsiyonlari idk - cond = idk C; - block size) shartini nirari ang Qtdod,

Model agnisi hajni deklaryatsiya bōlra masalan 256 tarix garabaliq uzun bōlra u xon olarin ang oxirgi 256 toqarni qirgib olib idkoriga uratechi

10. Nega oldam konfiguratsiyalarini (config) (un - ol. yam) kabi teshty faylga chiqaribchi

Javob xon sajar parametrlari (bayer, head size) o'zgaruvchan Model kodini o'zgartiruvchi Harol code qilmakchi va to'lovini so'zlash uchun.

Murakkab

1. Productionda nega MHA o'nini QA egallangola.

MHA da VRAM uddik bilan to'lovchi

QA da esa bittakey va Value metrikasini bir nechta Query bo'lariga guruhlash alashilochi.

KV cashe foydasi nimada? U Inference
vaqti-da VRAM da ma'lumotlar saqlanish
hajmini 4-8 barobar qisqartiradi.
Natijada bitta GPU bir vaqt o'zida
yuzlab foydalanuvchilar suxbotini o'tatib
olib turadi.

2. Tied Weights bo'lganda parametrlar
soni qanday to'g'ri hisoblanadi.

Embedding matritsasi va LM head aslida
jismonan bitta o'zgaruvchi bo'lgan uchun
jami parametrlar sonida bir marta
hajmi jihat hisabga olinishi kerak.

3. RoPE va Classic Learning foydalanish
farqi.

Klassik yondash beradi foydali natijalar
vaqti. Absolyut sifatida yashaydi.

RoPE esa beradi ma'nosiz natijalar
tri gonometrik fozda ma'lum burilish
berish. Rotating orqali ushbu
masofalarni aniqlaydi.

4. SWig LU arxitekturas: standart
Jekun duri jangi?

SWig LU bitta emas bir necha Chiziq
transformatsiyalar bilan foydalaniladi.
va u yerda o'rtasidagi shlyuzli mexanizm
joriy mehorizni mahorat o'tkazish
yoki o'tkazmaslik ishlatiladi.

Bu FPN tarkibini kattalashtirish
demonstratsiyasi o'zida.

5. Mega Frontier (GPT-4 (ama) modellovi
Dropout butunlay o'chirib tashlangan.
Kichik modellarda model mahoratlarini yodlay
qolishga moyil Ammo yirik modelde
+ millionlab beklarni 1 marta ko'rib
chiqadigan Single epoch tizimida o'ziga
shuning uchun yodlay olisha o'zi
deyarli imkoniyat drop out. va
ortig'ida biron xasifastu o'tab
qoladi.