

LLM-20y - 1 Dars.

Ikkinchi o'lasosiy nazorati tayyor modelni
yuklamasdan va mavjud modelni fine tuning
qilmasdan. Dora yig'ishdan deployment gacha,
end to end LLM pipeline qurishga o'tadi.

Google Colab $\Leftrightarrow$ Vs code

CPU, GPU, TPU farz leri.

pretraining va post training bosqich leri
handa real LLM loyixasida vaqt mehnat
va compute xarajat larinig qayerga
sarflanishini o'rganish.

Bizindii oy tayyor architecture
o'rganidik. Ikkinchi oyda esa tayyor
architectureni sotib olish emag, uning
component larinig yig'ish, sinavdan o'tkazish
va foydalanishga chiqarishni o'rganamiz.

Oldingi Bilim $\Rightarrow$ Yangi Maqsad $\Rightarrow$ Hisoblash
muhuri $\Rightarrow$ Modelni o'qitish $\Rightarrow$ Amaliy Vazifa.

LLMni noldan yaratish uchun
qaydagi tushunchalarni o'olindan bilish kerak.

token va tokenizatsiya.

embedding

self-attention

transformer blok

activation function

next token prediction.

Hugging Face

Local model va inference.

LLM nima?

U juda k6p matnlar asosida til idridagi

statistik va sennatik b6g lanishlarni 6rganadi.

matn yaratish, savolarga javob berish, tarjima
g'ilish, matn qisqartirish, kod yozish,
malumat ajratib olish va sinirning 6rskash
ketma-ket tahlil g'ilish.

LLM matnini inson cabi ongli ravishda
tushunadi deb oyltish texnik g'ihatdan
noldan tashqari soddalashtirishdir.

Uning asosiy va xisari berilgan konteks
asosida keyingi token larning ehtimollik
hisoblashdir.

Token tokenizatsiya.

Model matni to'g'idan to'g'ri harf yoki gap sifatida qabul qilmaydi. Matn avval tokenlarga bo'linadi.

Kitoblarni $\rightarrow$ kitob + lar + ini + ber

Har bir token vocabulargacha ichidagi $\pm D$ raqamga aylantiriladi. 1254 + 78 + 908 + 43

Vocabulargacha
tokenizator tashlagan tokenlar lugat.

Token ID Embedding.
oddiy raqam, masalan 1254 Bu raqamning o'zi kitob manosiini ifodalamaydi. Embedding g'alami har bir tokenni ko'p o'lchamli vektorga aylantiradi.

Token ID $\rightarrow$ Embedding Vector.

Manosi o'xshash tokenlarning vektori ekanligini farosida bir biriga yaqinlashishi mumkin.

Transformer tizimining o'zini bilishi bilan birgalikda uning gapdagi o'zini ham bilishi kerak. Boshqacha qilib
It bolani quradi. Tartib manosi o'zini bildiradi.

Self Attention
Modelga bir token boshqa tokenga qay
darajada e'tibor berishi kerakligini
aniqlash imkonini beradi.

$$\text{Attention}(Q, V, k) = \text{softmax}\left(\frac{Qk^T}{\sqrt{d_k}}\right)V$$

Ma'lumotdagi bir savolga javab berish uchun
Savol $\rightarrow$ Query. Ma'lumot qatnashchilarining
muhimliklari $\rightarrow$ Key. Ularning javoblari
Value. Savolga kimning bilimi ko'proq mas
bolsa, o'sha ko'proq e'tibor beradi.

Activation function

Relu, Gelu va SwigLU.

Activation function NNda nonlinear relationship
organish imkonini beradi.

Relu sodda va tez.

Gelu Transformer modellarida ko'p qo'llaniladi.

SwigLU ko'p qatlamli LLMlarda
samaraqli feed forward mexanizmi sifatida

Transformer architecture.

1. Token va position embedding.
2. Multi-head self-attention
3. Residual connection
4. Layer Norm
5. FFN
6. Takrorlanuvchi transformer bloklari.
7. Vocabulary bo'yicha logits chiqarishni o'z ichiga oladi.

Multi head Attention bir xil matnga bir nechta, nuqtai nazaridan qarash imkonini beradi.

Bir head grammatik bo'lanishni, boshqasi: uzoq mazozafigi kontextni, yana biri subyekt obyekt munosabatini tashkil etadi.

GPT-2 arxitekturasida:

1. Embedding layers.
2. Transformer blocks.
3. Attention
4. FFN layers.
5. Layer Normalization.
6. Language model head.
7. Parametrlar soni.

GPT2 decoder only transformer hisoblanadi u oldingi tokenlar asosida keyingi tokeni bashorat qiladi.

Hugging Face xotim.

transformers, datasets, tokenizers,
HF Hub, Spaces.

Local LLM va Ollama

Local LLM modelini o'z ichiga API ga so'rov yubormasdan o'z kompyuteriingizda ishlatishni anglatadi.

Privacy, No depending Internet, Fast API ↓,
tajriba ustidan ko'ra, nuzur.

Birinchisi o'g $\Rightarrow$ LLM qanda ishlaydi?
Ikkinchisi o'g $\Rightarrow$ LLMni noldan qanday loyixolash,
o'qitish va ishlatish mumkin?

No downloading ML models

No fine tuning

End to End LLM model.

Bu tayyor pretrained weightlarni yuqorilab olib
ishlatmaslikni anglatadi. Arxitektura g'oyalari
o'rganish mumkin. Ular modelning bilimlari
o'zimiz tayyor lagun datasetlarga kelishi
mumkin.

No fine tuning $\rightarrow$ Fine tuning mavjud pretrained
modelni maxsus vazifaga moslab
Bu loyixada esa boshlangich Nuzg
tayyor pretrained model emas. Proposed.

Random weights $\rightarrow$ Pretraining $\rightarrow$ Base Model

End to End deganda faqat
model klassini yozish emas butun zanjir
tushuniladi

Data topish $\rightarrow$ litsenziya tekshirish $\rightarrow$

Data tozalash $\rightarrow$ deduplication $\rightarrow$ tokenizer
train $\rightarrow$ Dataset yaratish $\rightarrow$ model arxitekt
turasini yozish.

training loop $\rightarrow$ evaluation $\rightarrow$ checkpoint
 $\rightarrow$ inference $\rightarrow$ Deployment.

To'g'or non so'fib olish $\rightarrow$ Pretrained model

To'g'or xamir pishirish $\rightarrow$ fine tuning

Buydoga'adan nonga'da $\rightarrow$ end to end

Build Our Own LLM

Ma'lumat qayg'olgan olinadi?

Qanday ma'lumat kerak?

Sifati qanday bitishi kerak?

Ko'p Data xat doim xat yaxshi model degani
emas. Natijasi tataror turgan yoki sifatli
data modelni xat sifatli qili badi.

Data Processing

3ta asosiy amal

Clean: HTML, buzilgan belgilar

keraksiz formatlarni tozalash.

Filter: Sifatli va mavzuga aloqasiz matn
olib tashlash.

De-duplicate. Bir xil yoki degan bir xil
matnlarni o'chirish.

Tokenizer.

BPE, BPEni o'qitish, vocabulary yasa
BPE ter ter uchrayoligan belgilar
juftligini bosqichma bosqich birlashtirish
Natijada ring tanalgan so'zlar ham
token, ham uchrayoligan so'zlar esa,
sub xordga bo'linadi.

Dataset.
Torabangan matn

token ID lar

belgilangan uzunlikdagi sequence
Batchlarga aylantiriladi.

Sequence model bir marta ko'radigan
tokenlar oynasi.

Batch parallel qayta ishlaydigan bir nechta
sequence.

Model

Embedding

Attention

FFN

Transformer blok

Modeling lastlabki weightlari bo'shlig bo'laoli
Pretraining davomida ular asta sekin ma'lumotga
moslashlarga moslashadi.

Pretraining

Model next token prediction vazifasi o'zida
o'qitiladi. Mayalan

Bugun havo qulda

model issiq, sovuq, yaxshi kabi token lar
ehtimolini chiqaradi.

Agar haqiqiy token issiq bo'lsa loss
modelning boshqarati bilan haqiqiy javab
orasidagi farqni o'lchaydi.

Keyingi jarayon

Forward Pass $\Rightarrow$ loss $\Rightarrow$ Backpropagation $\Rightarrow$
 $\Rightarrow$ Optimizer Step.

Backpropagation xatoning qaysi parametrlar
sababli yuraga e'lonini aniqlaydi. Optimizer
esa parametrlarni xatoni kamaytirish
yo'nalishida o'zgartiradi.

Evaluation

Validation Loss

Perplexity

Generation Sifati

bench marks.

Perplexity sad dalolatidir ayteyda modelning
keyingi token bo'ysida qandalik xatolar ekani
ifodalaydi $PPL = e^{loss}$.

odatda pastog perplexity yaxshiroq lekin
fagat bitta metrika modeling jafirligini
xavfsizligini va mantiqiy to'liq baxolanmaydi.

Inference

Checkpoint yuklash.

promptni tokenizatsiya qilish.

modeldan logit olish.

token tanlash.

tokenni kontekstga qo'shish.

jarayonni takrorlash.

tokenlarni matnga dekod qilish.

Checkpoint $\rightarrow$ video o'yinlari savepointga
o'xshaydi. Training toxtasig noldan boshlanmay
saqlangan holatdan davom ettiradi.

Deployment.

API, Server, Docker, lokal yoki cloud.

Model o'qitish oshxonada tayyor bo'lsa
o'zga tayyorlash bo'lsa deployment shu
o'zgarishni mijozga yetkazish resursant
xizmatidir.

Pretraining va Post training.

Eng qisqa farg.

Pretraining : modelga til va dunyodagi umumiy nashri o'rgatish.

Post-training pretrained moduli foydalanuvchi so'zlariga amal qilishga qaydali va raqsiy assistentga moslashtirilgan.

Work flow

Raw data $\rightarrow$ Custom BPE Tokenizer $\rightarrow$
Custom PyTorch Block $\rightarrow$ Pretraining Loop
 $\rightarrow$ Post Training $\rightarrow$ AI Assistant.

Raw Data va Cleaning

Web, kitob hujjat yoki Doshga marbublar kon matn olish. Ular tovarich filtrlash takrorlardan xalos qilinish.

Custom BPE Tokenizer.

Datasetga mos vocabulary yaratiladi.

Bu modeling training alifbasi bo'ladi.

Custom PyTorch Block.

embedding $\rightarrow$ attention $\rightarrow$ FFN $\rightarrow$

Normalization $\rightarrow$ Residual connection
Output Head.

Model next been Pretraining loop.
top markat o'g'itiladi. Natijada base model
olindi

Post training

SFT - Supervised Fine Tuning

Modelga yaxshi yozilgan Prompt.

But modelga favob format: va instruction
qo'llanish o'g'itiladi.

RLHF Reinforcement Learning from Human
Feedback.

Insanlar model javoblar baholaydi.

DPO Direct Preference Optimization.

Modelga tanlovchi va rad etilgan javob
juzt baholirini beradi.

LLM uchun Data set

Hugging Face

Common Crawl

Wikipedia Dump

Oscar yoki mC4

FineWeb

the Pile

Project Gutenberg

Kongle

GitHub

1. Nina Sababdan 10 ta follow up Savol.
baxshlar o'ziga alohida BPE tokenizer
faydali bo'lishi mumkin.
2. Datasetdagi taxroriy matnlar ro'yxatini
training va evaluation natijalariga
qanday ta'sir qiladi.
3. Pretraining va SFT o'rtasidagi asosiy
farq.
4. Nina uchun GPU transformer trainingda CPU
dan tezroq ishlaydi.
5. TPU bilan ishlaydigan PyTorch/KLA
nima vazifa bajaradi.
6. Validation loss va Perplexity modelda
haqiqat qanday natijaga e'la.
7. Training to'g'ri budget dataset hajmi
va epoxlar soniga qanday bog'liq.
8. Model parametrlar soni dataset hajmiga
nisbatdan kichikdan tashqari to'g'ri bo'lsa,
nima bo'ladi.
9. Checkpoint inference va deep beam o'rtasida
qanday farq bor.
10. Pretrain model nima uchun Post Train qilib,
yaxshi AI asistanti bo'lib qolmaydi.